

唐权威

LLM / RAG / Agent Algorithm

@ 1076451802@qq.com

📞 17790556197

🌐 blog.guanwei.fun

🔗 tangquanwei



实习

会议理解大模型 RD

AI Speech 思必驰

📅 2025/04 - 2025/09

📍 苏州

- LLM 时间戳建模：基于会议转写与音频对齐数据构造 SFT 任务，让 LLM 生成词级/句级时间戳，精确召回提升 10%+，并沉淀 bad case 分析流程。
- 热词与知识增强：融合语音、文本和业务热词知识，优化热词召回与语音问答效果；针对识别错误构建清洗样本，降低 ASR 误差传递。
- 检索推理链路：参与外部知识检索与引用路径生成，使回答可追溯；关注 RAG 场景下的 chunking、召回和 rerank 调优。

APA System / Agent RD

Momenta 魔门塔

📅 2025/09 - 2026/01

📍 苏州

- Agent 工作流：基于 LangChain/LangGraph 思路设计任务流自动化 Agent，串联需求解析、资料检索、多工具调用、状态追踪和结果反馈，降低跨平台操作成本。
- 自动 FIT-Checker：构建从需求文档到开发文档、代码修改、测试和 PR 的自动化链路；实现一系列 Fit-Checker，平均 P&R > 90%，显著减少人工检查时间。

语音-热词跨模态检索 RD

AI Speech 思必驰

📅 2026/01 - 2026/06

📍 苏州

- 跨模态检索建模：面向“语音中真实出现热词识别”任务，研发语音-热词检索方法，绕开 ASR 转写后文本匹配的误差传递。
- Token 对齐与训练：引入 CIF 将连续语音帧压缩为 acoustic tokens，设计长度感知滑窗与 token-level Text MaxSim；结合局部对比学习、CIF quantity 约束和辅助对齐目标训练。
- 数据工程与 Error Analysis：优化 batch 构造以过滤潜在 false negative，基于 bad case 定位召回/误报来源，提升跨模态检索稳定性。

项目

基于大语言模型的医药问答 RAG 研究

本科毕设

📅 2023/12 - 2024/05

- 领域微调：使用 LoRA/QLoRA 微调 ChatGLM-6B，完成医药 QA 领域知识注入，准确率较基线提升 10%。
- 检索增强生成：清洗 100k+ 原始数据得到 15,000 组 QA，使用 BGE-M3 向量化并结合 FAISS 索引，Top-5 召回率达到 98%。
- 量化部署：通过 4-bit 量化压缩模型显存占用，支持 CPU 端 2s 内端到端响应。

多模态知识图谱 - 作业风险管控系统

📅 2023/12 - 2024/07

- 非结构化解析：基于 Neo4j 构建“设备-环境-人员-流程”四维异构图谱，融合文档、视觉和结构化数据，沉淀 5000+ 风险实体。
- 视觉文本对齐：使用 YOLOv7 识别现场违规行为，结合 BiLSTM-CRF 从操作规范中抽取实体，实现多模态信息知识化。
- 可解释分析：应用 GNNExplainer 生成风险传播路径和审计报告，支撑“事前评估-事中监控-事后复盘”闭环，事故率降低 30%+。

教育

苏州大学

NLP Lab 硕 + 博

📅 2024/09 -

兰州交通大学

软件工程 本科

📅 2020/09 - 2024/06

- 专业排名：1/76 GPA：3.89/4
- CTE-4: 558 CET-6: 478

论文

- ACL 2026 Findings (一作)：Don't Just Listen, Try Planning: Graph-based Retrieval-Generation Agent for Long-form Audio Meeting Understanding.
- ACL 2025 Findings (一作)：A Comprehensive Graph Framework for Question Answering with Mode-Seeking Preference Alignment.
- ICASSP 2026 (一作)：Relative Time Intervals Representation for Word-level Timestamping with Masked Training.
- ICASSP 2026 (合作)：TASU: Text-Only Alignment for Speech Understanding.

技能

Python

PyTorch

Transformer

SFT/RLHF

LoRA/QLoRA

RAG

Milvus/Pinecone

LangChain/LangGraph

Agent

TensorRT-LLM

Neo4j

Git

Linux

Docker

Error Analysis