

唐权威

LLM / RAG / Agent Algorithm

@ 1076451802@qq.com

📞 17790556197

🌐 blog.quanwei.fun

🔗 tangquanwei



实习

会议理解大模型 RD

AI Speech 思必驰

📅 2025/04 - 2025/09

📍 苏州

- **LLM 时间戳建模**: 基于会议转写与音频对齐数据构造 SFT 任务, 让 LLM 生成词级/句级时间戳, 精确召回提升 10%+, 并沉淀 bad case 分析流程。
- **热词与知识增强**: 融合语音、文本和业务热词知识, 优化热词召回与语音问答效果; 针对识别错误构建清洗样本, 降低 ASR 误差传递。
- **检索推理链路**: 参与外部知识检索与引用路径生成, 使回答可追溯; 关注 RAG 场景下的 chunking、召回和 rerank 调优。

APA System / Agent RD

Momenta 魔门塔

📅 2025/09 - 2026/01

📍 苏州

- **Agent 工作流**: 基于 LangChain/LangGraph 思路设计任务流自动化 Agent, 串联需求解析、资料检索、多工具调用、状态追踪和结果反馈, 降低跨平台操作成本。
- **自动 FIT-Checker**: 构建从需求文档到开发文档、代码修改、测试和 PR 的自动化链路; 实现一系列 Fit-Checker, 平均 P&R > 90%, 显著减少人工检查时间。

语音-热词跨模态检索 RD

AI Speech 思必驰

📅 2026/01 - 2026/06

📍 苏州

- **跨模态检索建模**: 面向“语音中真实出现热词识别”任务, 研发语音-热词检索方法, 绕开 ASR 转写后文本匹配的误差传递。
- **Token 对齐与训练**: 引入 CIF 将连续语音帧压缩为 acoustic tokens, 设计长度感知滑窗与 token-level Text MaxSim; 结合局部对比学习、CIF quantity 约束和辅助对齐目标训练。
- **数据工程与 Error Analysis**: 优化 batch 构造以过滤潜在 false negative, 基于 bad case 定位召回/误报来源, 提升跨模态检索稳定性。

项目

基于大语言模型的医药问答 RAG 研究

本科毕设

📅 2023/12 - 2024/05

- **领域微调**: 使用 LoRA/QLoRA 微调 ChatGLM-6B, 完成医药 QA 领域知识注入, 准确率较基线提升 10%。
- **检索增强生成**: 清洗 100k+ 原始数据得到 15,000 组 QA, 使用 BGE-M3 向量化并结合 FAISS 索引, Top-5 召回率达到 98%。
- **量化部署**: 通过 4-bit 量化压缩模型显存占用, 支持 CPU 端 2s 内端到端响应。

多模态知识图谱 - 作业风险管控系统

📅 2023/12 - 2024/07

- **非结构化解析**: 基于 Neo4j 构建“设备-环境-人员-流程”四维异构图谱, 融合文档、视觉和结构化数据, 沉淀 5000+ 风险实体。
- **视觉文本对齐**: 使用 YOLOv7 识别现场违规行为, 结合 BiLSTM-CRF 从操作规范中抽取实体, 实现多模态信息知识化。
- **可解释分析**: 应用 GNNExplainer 生成风险传播路径和审计报告, 支撑“事前评估-事中监控-事后复盘”闭环, 事故率降低 30%+。

教育

苏州大学

NLP Lab 硕 + 博

📅 2024/09 -

兰州交通大学

软件工程 本科

📅 2020/09 - 2024/06

- **专业排名**: 1/76 **GPA**: 3.89/4
- **CTE-4**: 558 **CET-6**: 478

论文

- **ACL 2026 Findings (一作)**: *Don't Just Listen, Try Planning: Graph-based Retrieval-Generation Agent for Long-form Audio Meeting Understanding.*
- **ACL 2025 Findings (一作)**: *A Comprehensive Graph Framework for Question Answering with Mode-Seeking Preference Alignment.*
- **ICASSP 2026 (一作)**: *Relative Time Intervals Representation for Word-level Timestamping with Masked Training.*
- **ICASSP 2026 (合作)**: *TASU: Text-Only Alignment for Speech Understanding.*

技能

Python

PyTorch

Transformer

SFT/RLHF

LoRA/QLoRA

RAG

Milvus/Pinecone

LangChain/LangGraph

Agent

TensorRT-LLM

Neo4j

Git

Linux

Docker

Error Analysis