

唐权威

Multimodal LLM / Speech-Text Retrieval / Agent Dev

@ 1076451802@qq.com

📞 17790556197

🌐 blog.quanwei.fun

🔗 tangquanwei



实习

会议软件攻关 RD

AI Speech 思必驰

📅 2025/04 - 2025/09

📍 苏州

- **时间戳大模型训练** 实现“LLM 生成时间戳，精确召回提升 10%+
- **热词大模型训练** 多模态知识融合：结合语音和文本知识，降低语音识别错误率，提升语音问答准确率。
- **检索推理大模型训练** 可解释性增强：输出外部知识引用路径，确保知识引用可溯源。

APA System / Agent RD

Momenta 魔门塔

📅 2025/09 - 2026/01

📍 苏州

- **Agent 开发** 设计并开发任务流自动化 Agent，实现从任务提交提交、状态追踪到结果反馈的闭环处理，大幅降低跨平台操作的心智负担与响应延迟。
- **自动 FIT-Checker 开发** 构建高度自动化的开发工作流，输入需求文档，输出开发文档和 PR。Agent 根据需求文档查资料、写文档、写代码、测试、提交代码，人工只需要审核代码合入主线。开发了一系列 Fit-Checker 平均 P&R >90%，大大减少了人工检查的时间。

语音-热词跨模态检索 RD

AI Speech 思必驰

📅 2026/01 - 2026/06

📍 苏州

- **语音跨模态检索**：面向“语音中真实出现热词识别”任务，研发语音-热词检索方法，在语音流和文本知识之间直接建模，绕开 ASR 文本匹配的误差传递。
- **Acoustic Token 对齐**：引入 CIF 将连续语音帧压缩为 acoustic tokens，设计长度感知滑动窗与 token-level Text MaxSim，实现语音片段和文本 token 的细粒度匹配。
- **训练与误差分析**：结合局部对比学习、CIF quantity 约束和辅助对齐目标训练；优化 batch 构造以过滤 false negative，通过 bad case 定位召回/误报来源。

项目

基于大语言模型的医药问答 RAG 研究

本科毕设

📅 2023/12 - 2024/05

- **领域模型训练**：使用 LoRA/QLoRA 微调 ChatGLM-6B，完成医药 QA 领域知识注入，准确率较基线提升 10%。
- **检索增强生成**：清洗 100k+ 原始数据得到 15,000 组 QA，使用 BGE-M3 向量化并结合 FAISS 索引，Top-5 召回率达到 98%。
- **低延迟部署**：通过 4-bit 量化压缩模型显存占用，支持 CPU 端 2s 内端到端响应，关注生成内容的精炼性和可用性。

声学-文本跨模态对齐

📅 2026/01 - 2026/07

- **跨模态检索建模**：面向语音热词检索任务，构建不依赖完整 ASR 转写的声学-文本跨模态检索框架；基于 Paraformer + BERT 双塔结构，实现大规模候选热词检索。
- **Acoustic Token 对齐**：引入 CIF 将帧级语音表示压缩为 acoustic tokens，通过 quantity loss 约束声学 token 与文本 token 的长度一致性；结合局部滑动窗与 token-level MaxSim 定位长语音中的短热词片段。
- **两阶段训练与诊断**：实现 Stage1 CIF 预训练与 Stage2 联合检索训练，融合 local contrastive loss、CIF loss 和 token-level 辅助对齐目标，并处理 batch 内热词冲突导致的 false negative 问题。
- **部署与效果**：跑通数据处理、模型训练、量化部署和评估测试全流程；实现中文测试集 F1 96%+，英文测试集 F1 85%+，30s 语音、2k 热词检索延迟 <200ms。

教育

苏州大学

NLP Lab 硕士

📅 2024/09 - 2027/06

兰州交通大学

软件工程 本科

📅 2020/09 - 2024/06

• 专业排名：1/76 GPA：3.89/4

• CTE-4: 558 CET-6: 478

论文

- **ACL 2026 Findings (一作)**: *Don't Just Listen, Try Planning: Graph-based Retrieval-Generation Agent for Long-form Audio Meeting Understanding.*
- **ACL 2025 Findings (一作)**: *A Comprehensive Graph Framework for Question Answering with Mode-Seeking Preference Alignment.*
- **ICASSP 2026 (一作)**: *Relative Time Intervals Representation for Word-level Timestamping with Masked Training.*
- **ICASSP 2026 (合作)**: *TASU: Text-Only Alignment for Speech Understanding.*

技能

Python

PyTorch

DeepSpeed

Multimodal LLM

SFT/DPO

Audio-Text Alignment

Contrastive Learning

LoRA/QLoRA

CIF

RAG

FAISS/Milvus

Agent

Onnx

TensorRT

Neo4j

Git

Linux

Docker

Error Analysis