

唐权威

Multimodal LLM · Speech-Text Retrieval · RAG / Agent

@ 1076451802@qq.com

17790556197

blog.guanwei.fun

tangquanwei



实习经历

会议大模型算法研发实习生

AI Speech 思必驰

2025/04 – 2025/09

苏州

- 词级时间戳建模：参与会议场景下 word-level timestamping 模型训练与评测，优化 LLM 生成时间戳方案，精确召回提升 10%+。
- 热词增强语音理解：融合语音证据、候选热词与文本知识，降低 ASR 误识别对下游问答的误差传递，提升会议问答在领域实体上的稳定性。
- 可溯源检索推理：构建外部知识检索与引用路径输出机制，使模型答案能够关联到检索证据，增强会议问答结果的可解释性与可核查性。

APA System / Agent 研发实习生

Momenta 魔门塔

2025/09 – 2026/01

苏州

- 研发流程 Agent：设计任务流自动化 Agent，打通任务提交、状态追踪、结果反馈与异常提示，减少跨平台人工操作与信息同步成本。
- 自动 FIT-Checker：构建“需求文档 → 开发文档 → 代码实现 → 测试 → PR”的自动化工作流，人类主要负责代码审核与主线合入。
- 质量评估与落地：开发多类 FIT-Checker，平均 Precision / Recall 超过 90%，显著减少人工规则检查与回归验证时间。

语音-热词跨模态检索算法实习生

AI Speech 思必驰

2026/01 – 2026/06

苏州

- 端到端语音热词检索：面向“语音中真实出现热词识别”任务，构建不依赖完整 ASR 转写的 speech-hotword retrieval 框架，缓解文本匹配链路的误差传递。
- Acoustic Token 对齐：基于 CIF 将连续语音帧压缩为 acoustic tokens，结合长度感知滑窗与 token-level MaxSim，实现短热词片段与文本 token 的细粒度匹配。
- 训练诊断与优化：联合 local contrastive loss、CIF quantity loss 与 token-level 辅助对齐目标训练；分析 batch 内 false negative，优化采样与 bad case 诊断流程。
- 效果与性能：中文测试集 F1 达到 96%+，英文测试集 F1 达到 85%+；30s 语音、2k 候选热词检索延迟低于 200ms。

项目经历

Token-Level 后交互语音-热词检索

语音-文本跨模态检索

2026/01 – 2026/06

- 问题建模：将语音热词检索建模为局部声学片段与候选文本 token 的跨模态匹配问题，避免先转写再字符串匹配带来的级联错误。
- 方法设计：借鉴 ColBERT late interaction，引入 CIF acoustic tokenization、长度感知 local window 与 Text MaxSim，使模型保留 token 级匹配证据而非仅依赖全局 pooling 表示。
- 训练策略：实现 Stage1 CIF 对齐预训练与 Stage2 联合检索训练；针对多正例、子串热词与 batch false negative 设计诊断实验和加权训练策略。

基于大语言模型的医药问答 RAG 系统

本科毕业设计

2023/12 – 2024/05

- 领域模型训练：基于 LoRA / QLoRA 微调 ChatGLM-6B，完成医药 QA 场景的领域知识注入，准确率较基线提升 10%。
- 检索增强生成：清洗 100k+ 原始数据并构建 15,000 组 QA，使用 BGE-M3 向量化并结合 FAISS 建立索引，Top-5 召回率达到 98%。
- 低资源部署：通过 4-bit 量化压缩显存占用，支持 CPU 端 2s 内端到端响应，提升系统在低算力环境下的可用性。

教育背景

苏州大学

NLP Lab · 硕士研究生

2024/09 – 2027/06

- 研究方向：多模态大模型、语音理解、RAG / Agent、跨模态检索。

兰州交通大学

软件工程 · 本科

2020/09 – 2024/06

- 专业排名：1/76 GPA：3.89/4
- CET-4：558 CET-6：478

论文发表

- ACL Findings 2026 (一作)：Don't Just Listen, Try Planning: Graph-based Retrieval-Generation Agent for Long-form Audio Meeting Understanding.
- ACL Findings 2025 (一作)：A Comprehensive Graph Framework for Question Answering with Mode-Seeking Preference Alignment.
- ICASSP 2026 (一作)：Relative Time Intervals Representation for Word-level Timestamping with Masked Training.
- ICASSP 2026 (合作)：TASU: Text-Only Alignment for Speech Understanding.

技术栈

大模型训练

PyTorch

DeepSpeed

LoRA / QLoRA

SFT / DPO

Contrastive Learning

Error Analysis

语音与多模态

Multimodal LLM

Audio-Text Alignment

CIF

Speech Retrieval

RAG

检索与部署

FAISS / Milvus

Neo4j

ONNX

TensorRT

Agent